

知行 Agent

会规划 · 会查证 · 会使用工具 · 会读图的透明化 AI 智能助手

条目	内容
赛道方向	AI Agent 智能助手（2026 第九届传智杯全国大学生数智创新与 AI 应用大赛）
参赛组别	B 组
作品形态	Web 应用（React 18 + Vite 前端 / Node Agent 服务端），已提供公网在线演示
技术关键词	LLM · AI Agent · Function Calling · MCP · RAG · 多模态 · SSE 流式 · Web Speech
知识库规模	46 篇（赛事备赛 31 篇 + 校园学习 15 篇，双知识域可切换）
代码与测试	约 4800 行 TypeScript，66 项单元测试，ESLint / 类型检查 / 构建全量 CI 门禁
代码仓库	https://github.com/Solarward-1209/zhixing-agent
文档日期	2026 年 10 月

团队信息（队伍名称、成员分工、指导老师）见本文档 9.3 节，提交前请核对填写。

目录

1 项目概述

- 1.1 项目背景与选题方向
- 1.2 产品定位与核心价值
- 1.3 主要特性总览
- 1.4 开发与运行环境

2 需求分析

- 2.1 目标用户与使用场景
- 2.2 功能需求
- 2.3 非功能需求

3 系统架构设计

- 3.1 总体架构
- 3.2 事件协议设计
- 3.3 模块划分
- 3.4 关键设计决策

4 AI 技术方案

- 4.1 大模型集成质量（8%）
- 4.2 Agent 规划与行动循环（8%）
- 4.3 RAG 多知识域混合检索（6%）
- 4.4 多模态图片理解（5%）
- 4.5 AI 安全与可控性（4%）
- 4.6 MCP 与工具集成（4%）

5 核心功能实现

- 5.1 执行计划可视化
- 5.2 流式输出与思考状态可视化
- 5.3 工具卡片与来源引用
- 5.4 多知识域与场景迁移
- 5.5 语音交互
- 5.6 会话持久化与对话操作
- 5.7 演示模式设计

6 创新点说明

6.1 技术创新点

6.2 应用创新点

7 社会价值与商业潜力

7.1 社会价值

7.2 目标用户与使用场景

7.3 商业模式与定价

7.4 市场空间估算

7.5 竞争格局与差异化

7.6 成本结构与可持续性

7.7 风险与应对

8 测试与部署

8.1 测试策略与用例

8.2 构建与运行

8.3 部署方案

8.4 评审期服务保障

9 总结与展望

9.1 当前成果

9.2 路线图

9.3 团队信息

1 项目概述

1.1 项目背景与选题方向

2026 年被业界称为「AI Agent 元年」：大模型的能力边界从生成文本扩展到自主规划与调用工具。与此同时，通用对话产品的信任问题愈发突出——模型会用非常自信的语气给出并不存在的规则、时间与数字，而用户无从判断答案的依据。在教育与知识服务场景中，这种幻觉是致命的：一条错误的报名截止时间可能直接导致学生错过比赛。

本作品选择大赛推荐方向中的 **AI Agent 智能助手**，但不把它做成又一个聊天框，而是回答一个更具体的问题：**如何让 AI 的回答变得可核查、可追溯、可解释？** 因此我们把「执行过程透明化」作为产品核心，并把「有据可查」作为可信度基线。

1.2 产品定位与核心价值

知行 Agent 是一个透明化的 AI Agent Web 应用。面对复杂问题时，它会先给出**可见的执行计划**，再按计划**检索知识库、调用外部工具**，最后以**流式输出**给出带引用编号的回答；计划、检索、工具调用、引用来源全部在界面上实时呈现。

三条核心价值主张：

- **过程可信**：计划时间线由真实执行动作驱动，用户看到的每一步都确实发生过，不是装饰性动画。
- **结论可查**：知识库检索结果以编号引用标注在句末，来源卡片可悬停查看原文摘要。
- **能力可迁移**：同一套 Agent 架构挂载不同语料即可切换场景（赛事备赛 / 校园学习），工程上以多知识域落地，而不是写死在单一业务里。

1.3 主要特性总览

能力	实现要点	对应评分点
执行计划与真实执行严格对应	PlanTracker 按关键词把计划步骤与真实动作（检索 / 某次工具调用）绑定，匹配不到就不发进度事件	Agent/ workflow 设计（8%）
RAG 多知识域混合检索	BM25（域内独立统计）+ 可插拔向量检索（0.45/0.55 融合），词项覆盖率解释相关度，双知识域 46 篇	RAG 技术应用（6%）
工具与 MCP 集成	内置计算/时间/真实天气/图片理解	MCP/工具集成（4%）

	4 个工具；标准 MCP 客户端支持 tools/list 动态发现远端工具	
多模态融入主循环	图片由 Agent 自主调用 understand_image 工具，结果与检索结果共同参与生成	多模态能力（5%）
AI 安全与可信	输入归一化拦截、输出密钥遮蔽与高风险标记、专业建议免责声明、限流与体积上限	AI 安全与可控性（4%）
流式与状态可视化	九类 SSE 事件；token 按帧批处理渲染；六阶段状态文案与真实阶段一致	AI 交互体验（3%）
对话操作与语音	复制 / 重新生成 / 点赞点踩反馈持久化；Web Speech API 语音输入与回答朗读	前端交互体验（3%）
工程与质量	TypeScript 严格模式、ESLint、66 项单元测试、CI 门禁、代码分割与 gzip	前端工程质量（10%）

表 1-1 主要特性与评分点对应关系

1.4 开发与运行环境

类别	选型	说明
前端	React 18 + TypeScript 5 + Vite 5 + Tailwind CSS 3	单页应用，构建产物分包（react / markdown 独立 chunk）
服务端	Node.js 20+ / tsx	同一套 TypeScript 代码，开发态挂 Vite 中间件，生产态独立进程
大模型	OpenAI 兼容协议（DeepSeek / 智谱 GLM）	流式 + Function Calling，可配置降级模型
检索	自研 BM25 + 可插拔 Embedding 适配器	无外部依赖即可运行；配置 Key 后自动升级混合检索
质量	Vitest 2 + ESLint 9 + tsc --noEmit + GitHub Actions	lint / typecheck / test / build 全量门禁
部署	Railway（在线演示）+ Docker / Render 备选	密钥通过平台环境变量注入

2 需求分析

2.1 目标用户与使用场景

核心用户：参加学科竞赛、备考升学、需要频繁查询规章制度的高校学生。他们的共同特征是：问题答案有权威来源（官网公告、培养方案、政策文件），但信息分散、检索成本高，并且**不能接受错误答案**。

典型场景：

- 备赛咨询：报名时间、组别规则、评审标准、提交材料、奖项设置——答案必须能追溯到官方原文。
- 学业事务：选课退课、绩点计算、保研推免、四六级与考研时间线——需要把哪一步什么时候做讲清楚。
- 日常工具：精确计算、当前日期推算、真实天气——这类问题大模型心算或凭记忆回答并不可靠，必须走工具。
- 图片提问：把赛事截图、成绩单、课程表拍照上传，直接问图里的评审权重是多少。

2.2 功能需求

编号	功能	需求描述
FR-1	执行计划	复杂问题自动拆解为 2~5 步计划，步骤状态与真实执行严格对应
FR-2	知识库检索	按知识域检索语料，回答标注引用编号并展示来源卡片；检索不到时如实说明
FR-3	工具调用	计算 / 时间 / 真实天气 / 图片理解，统一 JSON Schema 契约，支持 MCP 动态工具
FR-4	多模态	图片上传后由 Agent 自主调用图片理解工具，并与检索结果协同生成回答
FR-5	流式回答	SSE 事件流推送 token，前端按帧渲染 Markdown
FR-6	对话管理	多会话持久化、复制、重新生成、点赞点踩、停止生成（含服务端取消）
FR-7	多知识域	同一 Agent 可在赛事备赛 / 校园

		学习 / 全部 之间切换检索范围
FR-8	语音交互	浏览器端语音输入与回答朗读，不支持时优雅降级
FR-9	安全与治理	输入风险拦截、输出密钥遮蔽与高风险标记、免责声明、限流与体积上限

表 2-1 功能需求清单

2.3 非功能需求

维度	指标	实现方式
可用性	大模型/网络异常时不得白屏或抛栈	三层兜底：请求超时重试 → 失败话术 → 全链路 try/catch
稳定性	单次请求 30s 超时，429/5xx 自动退避重试	AbortController + 指数退避 + 可选降级模型
可解释性	每一次检索与工具调用都可追溯	九类 SSE 事件 + 引用编号 + 词项覆盖率
安全性	不泄露密钥、不输出明显有害内容	输出侧密钥遮蔽 + 输入归一化拦截 + 免责声明
健壮性	畸形请求不得打爆服务	8MB 体积上限、IP 限流、history/message 严格校验
可维护性	改动可回归验证	66 项单元测试 + ESLint + CI 门禁

3 系统架构设计

3.1 总体架构




图 3-1 系统总体架构

3.2 事件协议设计

前后端之间不复用宽松的聊天消息，而是定义了一套**九类事件的执行协议**（shared/protocol.ts）。前端只负责把事件渲染成界面，服务端只负责产生事件，职责单一、可独立演进。

事件	载荷	前端表现
status	stage (understanding/planning/retrieving/tooling/answering/finished)	思考状态文案
plan	steps: 字符串数组	执行计划时间线
step_update	index、status、note	步骤状态与备注
tool_call	callId、name、args	工具调用卡片（加载态）
tool_result	callId、ok、result{summary,data,display}	按 display 渲染计算/天气/知识库/图片卡片
token	content	流式正文（按帧批处理）
sources	sources[]（可为空数组）	引用来源胶囊
error	message	红色错误条（安全拦截、超时、异常）

done	meta{mode,model}	结束流式、标注运行模式
------	------------------	-------------

表 3-1 九类 SSE 事件

3.3 模块划分

层	模块	职责
表现层	src/App.tsx、components/*	布局、空状态、移动端抽屉、消息渲染
状态层	src/hooks/useAgentChat.ts	SSE 客户端、按帧节流、多会话持久化、重生成与反馈
多模态层	src/utlis/image.ts、src/hooks/useSpeech.ts	图片压缩与 HEIC 转码、语音输入与朗读
编排层	server/agent.ts	理解→规划→行动→生成主循环、计划追踪、输出守卫
能力层	server/rag.ts、tools.ts、mcp.ts、vision.ts	多域检索、工具执行、MCP 动态工具、图片理解
接入层	server/llm.ts、api.ts、main.ts、demo.ts	模型客户端、SSE 端点与加固、生产服务器、演示模式
治理层	server/safety.ts	输入归一化拦截、输出遮蔽、免责声明、兜底话术

3.4 关键设计决策

- 为什么用 SSE 而不是 WebSocket: 本场景是单向的服务端推送执行过程，SSE 语义更贴合、实现更简单，且能复用 HTTP 中间件做限流与体积控制。
- 为什么计划步骤要与真实动作绑定: 早期版本把计划第二步硬编码为检索中，当模型生成的计划第二步其实是调用计算工具时，界面就会出现张冠李戴的假进度。现在改为按关键词把工具映射到步骤（calculate→计算、get_weather→天气…），匹配不到就不发事件——宁可少一条进度，也不给一条假进度。
- 为什么图片要作为工具而不是旁路: 独立视觉通道只能做单轮看图问答，无法与检索、其它工具协同。改成工具后，图片信息进入主循环上下文，才能出现图中评审权重加官网原文引用这类融合回答。
- 为什么演示模式也要真实执行检索与工具: 在没有 API Key 的环境中，我们希望展示的仍然是真实的检索与真实的工具调用，只有自然语言组织退化为模板，从而保证演示的可复现性与诚实性。

4 AI 技术方案

本章按大赛评分细则的六个考察点逐项说明**选型理由**、**集成方式与优化策略**，并在每个小节给出可验证的证据（测试用例或线上实测现象）。

4.1 大模型集成质量（8%）

选型理由：采用 OpenAI 兼容协议接入，内置 DeepSeek 与智谱 GLM 两套预设，不绑定单一厂商；既降低供应商风险，也便于用同一份代码对比不同模型的表现。

集成方式：非流式用于规划（temperature 0.3，追求稳定），流式用于回答（temperature 0.6，追求流畅），图片理解使用 0.4；全部支持 Function Calling。

优化策略（本轮重点补强）：

- **超时：**单次请求 30 秒（AI_TIMEOUT_MS 可调），避免网络卡死拖垮整个会话。
- **重试：**对 408/409/425/429/5xx 与网络抖动做指数退避重试（默认 3 次尝试），退避 400ms 起、封顶 4s 并带随机抖动，避免惊群。
- **降级：**配置 AI_FALLBACK_MODEL 后，主模型整体失败会自动切换备用模型。
- **取消：**全链路透传 AbortSignal，用户点停止或断开连接时立即取消上游请求，consumeSseStream 会主动 cancel 底层 reader，避免持续计费。
- **提示词约束：**System Prompt 明确规定始终使用简体中文，修复了实测中出现的中英混杂输出。

证据：线上实测 token 流式稳定、无中英混杂输出；异常路径均有兜底话术。

4.2 Agent 规划与行动循环（8%）

主循环为：**理解** → **规划** → **行动**（图片理解 / 检索 / 工具循环，最多 3 轮）→ **生成** → **收尾**。规划阶段让模型输出 JSON 计划（强制 JSON + 默认计划兜底），行动阶段把工具结果回填进消息列表后继续生成，形成完整的规划-行动-观察闭环。

本轮的关键修复——计划可视化的真实性：

问题	修复前	修复后
步骤索引	硬编码 index 0/1，与模型生成的计划无关	PlanTracker 按关键词定位步骤，并保证同一时刻只有一个步骤处于进行中
工具与步骤关系	任何工具调用都标在同一个步骤上	TOOL_STEP_KEYWORDS 把 calculate / get_weather /

		get_current_time / understand_image 分别映射到对应步骤
匹配不到时	仍会发出与实际不符的进度	不发进度事件（宁可少一条，也不给假进度）
阶段状态	工具执行期间仍显示正在生成回答	工具调用前后补发 status: tooling
收尾	时间线可能停留在进行中	completeAll() 把未完成步骤按顺序 补完

表 4-1 计划与执行一致性修复对照

线上实测：提问「帮我算一下 $(128*46+372)/4$ 等于多少，顺便告诉我今天几号」，计划为两步，事件序列为 index0 running→done (calculate) → index1 running→done (get_current_time)，与实际工具调用完全一致。

4.3 RAG 多知识域混合检索（6%）

架构：BM25 常驻 + 可插拔向量检索，两者分数各自归一化后按 0.45（BM25）/0.55（向量）加权融合。BM25 参数 $k1=1.5$ 、 $b=0.75$ ；标题在索引中重复 4 次、分类重复 2 次，使标题命中的权重显著高于正文偶然命中。

多知识域：每个知识域一个语料文件，**域内独立构建 IDF 与平均文档长度等统计量**，避免跨域稀释；检索既可限定单域，也可跨域。新增场景只需登记一个域并放入一个 JSON 文件。

可解释的相关度：早期版本把融合分统一归一化后，最高分恒为 1.00，界面上的最高相关度 1.00 没有任何信息量。现在改为展示 **词项覆盖率**（查询词项在命中文档中的覆盖率）并标注所属知识域，例如「[校园学习] 召回 3 条，最高词项覆盖率 62%」。

降级策略：向量索引构建失败或查询向量失败时静默回退 BM25，检索层永不抛错；未配置 EMBEDDING_API_KEY 时使用纯 BM25，功能完整可用。

知识域	篇数	内容范围
赛事备赛 competition	31	大赛规程、评审细则、提交要求、奖项设置，以及 16 条赛道的介绍
校园学习 campus	15	选课学分、绩点保研、四六级与考研时间线、实习就业、学术规范、心理与事务办理

表 4-2 双知识域语料构成

4.4 多模态图片理解（5%）

融合方式：图片理解被封装为 `understand_image` 工具（而不是独立旁路）。用户上传图片后，Agent 先调用该工具获得结构化描述，把描述注入系统上下文，再与知识库检索结果一起生成最终回答，因此可以出现图中权重加官网原文引用的融合结论。

工程细节：前端对图片做本地归一化——长边压到 1600px、JPEG 质量 0.85、HEIC（iPhone 相册格式）统一转码为 JPEG；服务端二次校验（仅接受 `data:image/` 前缀、单图体积上限、一次最多 2 张）。未配置视觉模型时返回可执行的配置引导；配置了但调用失败时明确区分未配置与调用失败，并给出排查建议。

线上实测：上传测试图片后，事件序列为 `understanding→planning→tooling→retrieving→answering`，模型自主调用 `understand_image` 准确转写出图中的标题、截止时间、组别与编号，并在回答中与知识库引用 [1] 合并。

4.5 AI 安全与可控性（4%）

采用输入拦截、输出治理、兜底降级三道防线，并明确其能力边界（规则级，非模型级）：

防线	机制	实现要点
输入侧	归一化风险拦截	先做全角转半角、去空白与装饰符号、统一小写，再匹配 8 类风险规则；赌 博、赌*博 等简单绕过写法同样命中；命中后发 <code>error</code> 事件（前端红色错误条）
输出侧	密钥遮蔽 + 高风险标记	流式输出按 64 字符尾缓冲扫描，遮蔽疑似 API Key 与令牌（跨 <code>chunk</code> 也能命中）；若模型输出复现高危内容，追加安全提示
合规	专业建议免责声明	涉及医疗/法律/投资等关键词时自动追加免责声明（真实模式与演示模式一致生效）
抗滥用	限流与体积上限	每 IP 60 秒 30 次滑动窗口限流（429 + <code>Retry-After</code> ）；请求体上限 8MB；消息 4000 字上限
降级	兜底话术	任何异常都转为友好提示，绝不把堆栈抛给用户

表 4-3 AI 安全三道防线

诚实披露：当前为规则级实现，应对校园与备赛等低对抗场景足够；面向公网开放的生产系统建议叠加专业

内容审核 API 或分类模型，已列入路线图。

4.6 MCP 与工具集成 (4%)

内置工具（统一 JSON Schema 契约，与 Function Calling 直接对接）：`calculate`（递归下降解析器，不使用 `eval`，支持 `+-*/%` 与括号）、`get_current_time`、`get_weather`（真实数据源 Open-Meteo，免 Key，支持全球城市）、`understand_image`。

标准 MCP 客户端（本轮新增）：实现了 MCP 的 Streamable HTTP 传输与 JSON-RPC 2.0 方法子集——`initialize` → `notifications/initialized` → `tools/list` → `tools/call`。通过 `MCP_SERVERS` 环境变量声明一个或多个 Server 后，远端工具会被**动态发现**、转换为 Function Calling Schema 并注册进同一张工具表，与内置工具无差别参与 Agent 决策；调用结果中的 `content` 数组会被拼接为文本回填模型。

```
# 环境变量声明即可接入，无需改代码
MCP_SERVERS=[{"name":"filesystem","url":"https://your-mcp-host/mcp",
               "headers":{"Authorization":"Bearer xxx"}}]
# 或单个 Server 简写
MCP_SERVER_URL=https://your-mcp-host/mcp
```

可靠性设计：工具清单带 5 分钟 TTL 缓存，避免每次问答都做一次握手；未配置、网络不可达或协议不兼容时静默降级为内置工具，不阻塞主流程；调用失败会作为工具失败结果回填模型，由模型向用户如实说明。

证据：`tests/mcp.test.ts` 用一个真实的本地 HTTP MCP Server 跑通握手 → `tools/list` → `tools/call` → 统一 `executeTool` 调用 全链路，并覆盖未配置、非法配置、服务不可达三类降级路径。

5 核心功能实现

5.1 执行计划可视化

这是本作品最核心的交互创新，也是本轮重点修复的正确性问题。计划时间线的每一步状态都由服务端的真实动作驱动：检索开始时点亮检索步骤，某个工具被调用时点亮对应步骤，调用结束立即置为完成，收尾阶段把剩余步骤补齐。前端只做渲染，不猜测状态。

实现要点：PlanTracker 持有步骤数组与状态数组，通过关键词定位步骤；保证同一时刻至多一个步骤处于进行中；重复更新同一状态会被忽略（幂等）；收尾调用 `completeAll()` 兜底，避免时间线永远停留在进行中。

5.2 流式输出与思考状态可视化

服务端以 SSE 逐段推送 token，前端 `useAgentChat` 把 token 累积到缓冲区，通过 `requestAnimationFrame` 按帧刷新一次状态，把早期每个 token 一次 `setState` 的开销降低到每帧一次；长文本流式渲染时输入框与滚动不再卡顿。

状态条用六阶段文案（理解问题 / 制定计划 / 检索知识库 / 调用工具 / 生成回答 / 已完成）呈现 Agent 的思考过程；工具执行阶段会明确显示正在调用工具，而不是笼统的正在生成。

5.3 工具卡片与来源引用

工具结果通过 `display` 字段驱动生成式 UI：计算结果渲染为等宽的表达式等于结果卡片，天气渲染为城市、天气、温度、提示的结构卡片并标注数据来源（实时 / 离线样例），知识库检索渲染为召回摘要卡并给出词项覆盖率，图片理解渲染为描述摘要卡。

知识库检索结果以编号引用显示在句末，底部来源胶囊悬停可查看原文摘要；即使检索不到高相关内容，也会发送空的 `sources` 事件，让用户明确知道系统已经检索过。

5.4 多知识域与场景迁移

系统内置两个知识域：赛事备赛（31 篇）与校园学习（15 篇）。用户可在侧栏一键切换，服务端对 `domain` 参数做白名单校验后限定检索范围，并在系统提示中告知模型当前挂载的知识域。

这一设计的价值不只是功能本身，而是**证明架构的可迁移性**：新增一个场景（例如企业知识库、政务办事指南）只需放入一份 JSON 语料并登记一个域，规划、检索、工具、引用、安全治理全部复用。这是本作品从备赛工具走向通用可信问答引擎的关键一步。

5.5 语音交互

基于浏览器原生 Web Speech API 实现，无第三方依赖：输入侧提供语音转文字按钮，识别结果追加到输入框，识别中的临时文本实时回显；回答侧提供朗读按钮，朗读前会剥离 Markdown 记号与代码块，避免读出无意义符号。浏览器不支持或未授权麦克风时，按钮隐藏或给出明确提示，不影响文字交互。

5.6 会话持久化与对话操作

会话与消息保存在 localStorage，刷新或重开页面后自动恢复；支持新建、切换、删除会话，并会在新建时清理历史遗留的空会话。每条回答下方提供复制、重新生成、有帮助、需改进四个操作，反馈随会话一起持久化，可用于后续收集真实使用评价。用户点停止时前端中断连接，服务端同步取消上游请求。

5.7 演示模式设计

未配置 API Key 时自动进入演示模式：完整走一遍规划 → 检索 → 工具 → 流式回答的流水线，其中检索与工具是**真实执行**，回答由知识库原文要点组织并保留引用编号，不做无依据编造。这样即使评审在无外网、无密钥的环境下复现，看到的也是真实的能力而非静态截屏。

6 创新点说明

6.1 技术创新点

编号	创新点	说明
T1	计划与执行严格映射的透明化 Agent	不是把计划当装饰动画，而是把每一个工具调用、每一次检索映射回计划步骤；匹配不到就不发进度，用'宁可少一条，不给假进度'保证可视化的可信度
T2	多知识域 + 域内独立统计的混合检索	每域独立构建 BM25 统计量避免跨域稀释 IDF；配置 Embedding 后自动升级为 0.45/0.55 融合检索；相关度以词项覆盖率解释而非无信息量的归一化分数
T3	多模态作为工具进入主循环	图片理解被封装为 understand_image 工具参与规划与工具循环，可与检索结果协同生成，而非独立的单轮看图问答
T4	标准 MCP 客户端与动态工具发现	实现 MCP Streamable HTTP 传输与 initialize / tools/list / tools/call 方法子集，远端工具动态注册进同一张工具表，与内置工具无差别参与决策
T5	演示与真实双模式同构	无密钥时检索与工具仍真实执行，只有自然语言组织退化为模板，保证可复现性与诚实性
T6	流式输出治理	输出按 64 字符尾缓冲扫描遮蔽疑似密钥（跨 chunk 生效），并在结尾统一追加免责声明

表 6-1 技术创新点

6.2 应用创新点

- **全过程透明的人机协作范式：**把 AI 的黑盒回答变成可回放、可核查的执行记录，让用户从相信模型转变为验证依据。
- **一张知识库支撑多场景：**赛事备赛与校园学习共用同一套 Agent，说明该范式可迁移至校园服务、企业知识管理与政务办事指引等高价值场景。

- **低门槛可复现：**天气使用免 Key 的真实数据源，检索在无 Embedding 时仍完整可用，评审无需额外配置即可验证核心能力。
- **无障碍增强：**语音输入与朗读让不便键盘输入的用户也能使用。

7 社会价值与商业潜力

7.1 社会价值

缩小信息差，促进教育公平。 备赛与升学信息长期集中在少数信息灵通的学生手里：官网公告、赛道详情、培养方案、政策文件分散在不同入口，检索成本高，而通用大模型又不可信（会编造截止时间）。本作品把这些权威信息整理为可检索语料，用引用编号把答案锁定到原文，让任何一所学校、任何一个学生都能得到与信息灵通者同等质量的信息服务。

以透明化对抗幻觉，推动可信 AI 落地。 可信 AI 的核心不是让答案更像人，而是让答案能被验证。本作品把执行计划、检索证据、工具结果与引用来源同时呈现，为用户提供了判断答案可信度的依据，也为 AI 在教育、医疗、政务等高风险场景落地提供了一个低成本的工程范式：**先透明，再智能**。

无障碍与包容性。 语音输入与朗读降低了使用门槛，对视障用户、行动不便用户以及不擅长键盘输入的用户更友好。

7.2 目标用户与使用场景

用户群体	核心诉求	付费意愿	切入方式
高校在校生（C 端，规模大）	备赛咨询、学业规划、日常工具	低（但可转化为口碑与数据）	免费版：单知识域 + 全部工具
高校教务 / 就业指导中心（B 端）	政策与流程问答自动化，答案必须可溯源	中高（预算稳定、可年度续费）	订阅制：知识库接入 + 多席位
教育机构 / 企业培训部门（B 端）	私有知识库问答，数据不出内网	高（客单价高）	私有化部署授权 + 年度运维
企业知识管理团队（B 端）	内部制度、技术文档问答	高	按席位订阅 + 定制语料工程

表 7-1 目标用户与付费结构

7.3 商业模式与定价

采用 **B 端订阅为主、C 端增值为辅** 的双轨模式：

- B 端 SaaS 订阅：**按席位与知识域数量计费，含语料工程、检索调优与年度运维；面向高校与培训机构，建议定价区间为每校每年 3 至 5 万元（含 50 至 200 席位）。
- 私有化部署授权：**一次性授权费加年度运维费，面向对数据边界敏感的企业与政务客户。

- **C端增值**：免费版提供单一知识域与全部工具；会员版（建议 9.9 元/月）解锁多知识域、答案导出、语音高级音色与个人知识库上传。
- **增值服务**：语料整理与知识工程实施——这是很多 B 端客户真正的痛点，也是我们已具备的能力（本作品的 46 篇语料即为自建）。

7.4 市场空间估算

以高校市场为第一站：全国高等院校约 3000 余所，若按每校年均 3 至 5 万元的教育产品采购额保守测算，仅高校教务与就业指导方向的市场容量即在 **1 亿至 1.5 亿元/年** 量级；叠加企业培训、考试培训与内部知识管理需求，可触达市场显著更大。

从用户侧看，全国在校本专科生与研究生规模在数千万量级，即便只有 1% 的学生成为活跃用户、其中 5% 转化为会员，也对应百万级付费用户体量，足以支撑一个健康的垂直产品。

说明：本节数据为基于公开规模的量级估算，用于说明商业可行性，不构成收入承诺。

7.5 竞争格局与差异化

对比对象	优势	本作品的差异化
通用助手（Kimi / 文心 / 通义）	模型能力强、生态大	不拼模型，拼 垂直权威语料 + 过程可视化 + 引用溯源 ；通用助手难以保证校园政策的时效与准确
校园官网 / 教务系统	信息权威	传统系统是检索式与表单式，用户需要自己找；本作品是对话式且答案带出处，还支持图片与语音
其他 AI 助手类参赛作品	功能相近	多数作品止步于“能聊天”；本作品把 执行过程做成可验证的证据链 ，并实现了标准 MCP 工具发现与多知识域迁移
企业知识问答产品	面向 B 端成熟	本作品在架构上与其同构但更轻量，且已验证双模式与无密钥可复现，适合预算有限的高校与中小机构

表 7-2 竞争格局与差异化定位

7.6 成本结构与可持续性

成本侧：推理成本是用量线性增长的主要成本项。本作品通过三项工程手段压低边际成本——**检索优先**（先查语料再生成，减少无效生成）、**工具替代心算**（精确计算与时间不消耗推理 token）、**按帧节流与响应长度约束**（降低前端与模型双侧开销）。此外 BM25 常驻、向量可选，使无 Embedding 的环境也能零外部依赖运行。

收入侧与黏性：知识库是可沉淀的数据资产，随赛事周期与培养方案更新持续迭代，形成订阅粘性；语料工程能力可复制到新客户，边际交付成本递减。

可持续性的工程前提：系统在无外网密钥时进入演示模式仍可用，这意味着校园内网、涉密单位的私有化部署成为可能——这正是 B 端采购的关键门槛。

7.7 风险与应对

风险	影响	应对措施
大模型幻觉仍未完全消除	错误结论损害信任	引用编号强制溯源 + 检索不到时如实说明 + 工具替代心算 + 输出侧治理
模型服务中断或额度耗尽	在线演示不可用	超时重试与降级模型；自动进入演示模式；健康检查定时探活并留痕
知识库时效性	政策更新后答案过期	语料自带版本字段与来源标注；规划中的后台更新与版本对比能力
数据与隐私合规	B 端采购风险	默认不收集用户数据；支持私有化部署；密钥仅通过环境变量注入
同质化竞争	评审区分度不足	以过程透明化与 MCP 工具生态作为差异化技术锚点，持续补齐端侧与语音能力

表 7-3 风险与应对

8 测试与部署

8.1 测试策略与用例

采用 Vitest 做服务端逻辑的单元与集成测试，总计 **66 项用例**，全部离线可复现（MCP 测试使用本地 HTTP 服务器模拟真实握手，不依赖外网）。

测试文件	用例数	覆盖范围
tests/rag.test.ts	16	BM25 召回准确性、topK 限制、分数区间与排序、来源映射、相关性判定，以及多知识域的域隔离与跨域检索
tests/tools.test.ts	19	计算器精确求值（6 组）、除零与非法输入、时间工具、天气真实数据解析与 WMO 映射、失败不返回假数据、图片理解工具、Schema 契约完整性、工具名唯一性
tests/mcp.test.ts	8	MCP 配置解析、工具名转换、真实 HTTP 握手与 tools/list、通过统一 executeTool 调用远端工具、未配置与不可达的降级
tests/safety.test.ts	12	风险话题拦截与变形绕过、归一化、输出密钥遮蔽、高风险输出标记、免责声明
tests/vision.test.ts	8	图片格式与数量校验、视觉消息构建、未配置的引导话术、已配置但失败的可执行提示
tests/agent-demo.test.ts	3	演示模式完整流水线：数学问题走工具、赛事问题带引用、风险输入直接拒绝且不调用工具

表 8-1 测试用例分布

8.2 构建与运行

npm install	# 安装依赖
npm run dev	# 开发模式 (http://localhost:5173)
npm test	# 66 项单元测试
npm run lint	# ESLint 门禁
npm run typecheck	# TypeScript 严格模式类型检查
npm run build	# 类型检查 + 生产构建 (分包)
npm run server	# 独立生产服务器 (静态托管 + gzip + /api, 默 8787)

环境变量通过 `.env`（本机）或平台环境变量（部署）注入，全部可配置项已在 `.env.example` 中列出，包含大模型、视觉模型、向量检索、天气模式、MCP、限流与体积上限等分组说明。

8.3 部署方案

提供四条部署路线（详见仓库 `DEPLOY.md`）：**Railway / Render**（连接仓库自动部署，推荐）、**Docker**（镜像内不含任何密钥，运行时注入）、**裸机 + pm2**。在线演示地址：<https://zhixing-agent-production.up.railway.app>

为什么不用 Serverless 静态托管：本作品的 `/api/chat` 是基于常驻连接的 SSE 流式接口，需要长驻进程承载，因此选择 Railway / Render / Docker 这类长驻方案；如需迁移到 Serverless，可将 `server` 层改写为 Next.js Route Handler（已列入路线图）。

8.4 评审期服务保障

- **保活**：GitHub Actions 每 10 分钟探活一次 `/api/health`，既避免免费档实例休眠，也在服务异常时于 Actions 留下红色记录（可通过仓库变量 `DEMO_URL` 切换地址）。
- **额度**：评审期使用独立 API Key 并预留额度；即使额度耗尽，应用会自动进入演示模式，检索与工具仍然真实执行。
- **降级预案**：演示视频与本地运行记录作为兜底证据；`/api/health` 可随时确认当前模式、知识库规模与图片理解可用性。

9 总结与展望

9.1 当前成果

知行 Agent 已完成从“能聊天”到“可验证”的完整闭环：透明的执行计划、可追溯的引用、真实的外部工具、进入主循环的多模态、标准 MCP 工具发现、多知识域场景迁移、以及输入输出双侧的安全治理。工程质量上，约 4800 行 TypeScript 通过严格类型检查与 ESLint，66 项单元测试与 CI 门禁保证可回归，生产构建完成代码分割与 gzip 优化，线上演示地址持续可用。

9.2 路线图

阶段	事项	价值
近期	知识库升级为向量入库（pgvector / Milvus），支持文档上传与自动分块	从固定语料走向用户自有语料
近期	接入更多标准 MCP Server（文件系统、浏览器、数据库），实现工具动态发现	从自建工具走向生态工具
中期	端侧智能：Transformers.js / WebGPU 浏览器端小模型推理	降低推理成本与隐私风险
中期	生成式 UI 增强：工具结果渲染为图表与时间线（ECharts）	提升信息密度与可读性
中期	Multi-Agent 编排：Planner / Executor / Reviewer 三角色协作	复杂任务的质量与可靠性提升
远期	多租户与权限体系、语料版本管理与评测集	具备真正的 B 端交付能力

9.3 团队信息

项目	内容
队伍名称	_____（提交前填写）
成员及分工	_____（提交前填写）
指导老师	_____（提交前填写）
参赛组别	B 组（非 985/211 普通本科院校本科生）

表 9-1 团队信息